



윤치현

AI 연구원 & 엔지니어

chichi8969@naver.com | +82-10-8996-6964

github.com/ChihyeonYoon | chihyeonyoon.github.io

- ◆ **멀티모달 자동 편집 (석사 연구 & First Author):** 발화 인지 Swin Transformer와 Diarization (WhisperX / Pyannote) 오디오-비주얼 신호를 융합 분석하고 빔 서치(Beam Search)로 최적 채널 시퀀스를 추정하는 Late-Fusion 프레임워크 연구 (전문가 대비 90.10% 일치).
- ◆ **공간 AI & 메타버스 (ETRI 실무):** 가상-현실 공간 매핑을 위한 시각 기반 위치 추정(VPS) Localization 파이프라인 개발 및 모바일 XR 테스트베드 검증. VLM 적용 시맨틱 분석 기반 제로 샷(Zero-shot) 이상행위 실시간 탐지 알고리즘 설계.
- ◆ **3D 복원 & VLA 로봇틱스 (PoC):** 2D MT-DUNet(DCNv2)과 Beer-Lambert 3DGS를 결합한 sparse-view X-ray 관상동맥 3D 복원 알고리즘 최적화(L4 GPU 메모리 8배 절감). SmolVLA 기반 Unity ROS 로봇 제어(Pick & Place) 파이프라인 구축.

📁 Research & Career Timeline

2025.02 - 2025.06

한국전자통신연구원 (ETRI)

콘텐츠연구본부 초실감메타버스연구소 석사후연수연구원. 가상 공간 시각 기반 위치 추정 (VPS) 연구 및 VLM 기반 제로샷 이상행위 모니터링 시스템 구축. R&D 국책 과제(명세서 및 보고서 작성) 공동 관리.

2023.03 - 2025.02

경북대학교 대학원

인공지능학 석사 졸업 (학점 4.11/4.3). 멀티모달 언어 및 인지 연구실 소속. 비정형 오디오-비주얼 멀티모달 신호 처리, 디퓨전 오디오 합성, 적대적 학습 모델 최적화 연구 수행.

🔧 핵심 기술 스택

딥러닝 & 오디오

PyTorch

Transformers

DiffWave

WhisperX

Pyannote.audio

Librosa

비전 & 로봇틱스

3DGS

Visual SLAM/VPS

MT-DUNet

SmolVLA

ROS/ROS2

Unity

AI 의료 영상 복원



3D 형상 복원

LCA CAG 3DGS Reconstruction & Dashboard

2D Multi-Task Deformable UNet(MT-DUNet)과 Beer-Lambert 법칙 기반 3D Gaussian Splatting(3DGS)을 융합하여 희소한 2D C-arm X선 혈관 조영 영상으로부터 3D 관상동맥의 중심선, 반경 프로파일 및 형상을 복원하는 PoC 시스템.

- ◆ **Multi-Task Deformable UNet**: DCNv2를 아키텍처에 결합하여 굴곡진 혈관 형상에 강건하게 대응하고, 바이너리 마스크와 25개 해부학적 분지 라벨을 동시에 정밀 예측.
- ◆ **클래스 제한 삼각측량**: 에피폴라 매칭 시 동일한 해부학적 분지 라벨만을 추적하여 허상(ghost-point)을 근본적으로 제거하고 3D 중심점 밀도를 4.5배 높임.
- ◆ **Beer-Lambert 3DGS**: X선 투과 특성을 모델링하기 위해 광선 밀도 적분 수식을 적용하여 혈관 반경(r) 및 불투명도(α)를 최적화하는 미분 가능 렌더링 파이프라인 수립.
- ◆ **연산 효율화**: L4 GPU 상에서 데이터 포인트 다운샘플링 및 다중 해상도 렌더링 최적화를 적용하여 GPU 메모리 8배 절감(2.5 GiB 구동 성공).

사용 기술: PyTorch, 3DGS, Deformable Conv (DCNv2), Python, HTML/JS



AI 에이전트


RAG 검색 시스템

Chihyeon.ai Personal RAG Assistant

치현님의 학술 논문, 경력 상세 기술서 및 프로젝트 설명서 지식베이스를 연동하여, 방문자 질문에 사실 기반의 실시간 스트리밍 답변을 제공하는 고품질 AI 비서 챗봇.

- ◆ **고품질 파싱:** LlamaParse 및 Jina Reader API를 결합하여 학술 논문의 복잡한 표, 수식 기호, 그리고 동적 렌더링 웹 내용을 완벽히 추출.
- ◆ **글로벌 서버리스 아키텍처:** Vercel Functions Proxy 서버를 경유하여 백엔드 API 키 노출을 완벽히 방지하고 글로벌 접속 제한 문제를 해결.
- ◆ **고속 임베딩 질의:** 3072차원의 Pinecone 벡터 데이터베이스 공간에 지식을 연동하고 Gemini 2.5 Flash를 사용하여 지연 없는 실시간 스트리밍 답변 전송.

사용 기술: Gemini 2.5 Flash, Pinecone (Serverless), Vercel Functions, LlamaParse, Jina Reader, Python



로보틱스


시뮬레이션

Unity Pick & Place SmolVLA Integration

다중 모달리티 행동 제어 모델인 SmolVLA를 활용하여 로봇 팔의 '물건 집기 및 놓기 (Pick and Place)' 동작을 Unity 3D 가상 물리 엔진상에서 시뮬레이션 및 제어 연동한 개발 건.

- ◆ **바이브 코딩(Vibe Coding) 방법론:** 인공지능 어시스턴트(LLM)와 적극 협업하여 복잡한 네트워크 통신 및 시스템 연동 보일러플레이트 코드를 신속히 빌드하고 핵심 알고리즘 설계에 집중.
- ◆ **통신 파이프라인 연계:** ROS-Unity Integration 기술을 응용하여 가상 공간의 이미지 피드를 SmolVLA 추론 서버로 전달하고 Action 모션을 joint torque로 피드백하는 전이 파이프라인 구축.
- ◆ **시각 피드백 루프:** 가상 카메라 이미지 스트림을 받아 SmolVLA에 이진트가 위치 제어 토크 값을 연산하여 가상 로봇 팔을 구동하는 실시간 페루프 제어 검증.

사용 기술: SmolVLA, Multimodal LLM, Unity Engine, ROS, Docker, PyTorch



01

국제 학술지 제출 대기 중 (Pending Submission)

Seamless Multi-Hypothesis Video Editing Using Deep Multimodal Analysis Over Multi-Channel Sources

다채널 카메라 환경에서 취합된 시각(얼굴/발화 행동) 및 청각(오디오 스트림) 신호를 융합 분석하고 전문가의 컷 전환 문맥을 학습하여 자연스러운 편집 비디오를 자동 생성하는 엔드투엔드 시스템.

- 동기화된 화자 분리(WhisperX / Pyannote) 기술과 Swin Transformer 모델을 기반으로 시청각 정보를 정합하고, 빔 서치(Beam Search) 최적 시퀀스 예측 디코더를 구현하여 현업 편집 전문가의 결과물과 90.10% 일치하는 완성도 높은 영상 컷 추천 알고리즘을 제안하였습니다.

사용 기술: Speaker State Estimation, Swin Transformer, WhisperX, Pyannote.audio, Beam Search, Python


Seamless Multi-Hypothesis Video Editing Using Deep Multimodal Analysis Over Multi-Channel Sources

Introduction

- An automated system for editing multi-channel video by synchronizing raw inputs through separate visual and auditory pipelines.
- Deep late-fusion of multimodal information for face recognition, speaking-state estimation, speech recognition and speaker identification.
- A multi-hypothesis editing approach that provides candidate versions based on probability distribution over time for extracting frames from each channel stream.
- Frame-level match accuracies of 84.99% and 90.10% for the 3-channel and 5 channel videos, highlighting the system's robust performance across varying speaker complexities.

Method

- For multi-speaker, multi-channel content, we adopted an **intuitive approach** to make automated editing feasible. This is primarily because **datasets containing multi-speaker, multi-channel videos paired with their fully edited versions are extremely rare**.
- The lack of such datasets makes it challenging to apply standard supervised learning techniques effectively for automated video editing.
- For the audio modality, our goal is to accurately detect active speech segments and identify the corresponding speakers from diverse and often noisy multi-channel sources. - **Speech Recognition, Speaker Identification**
- The visual approach involves estimating the speaking state based on the facial region of the speaker. - **Face Detection, Speaking State Estimation**
- Integration and Channel Selection - **Multi-Hypothesis Generation for Temporal Coherence**



Experiment & Result

- Dataset
 - Studio recordings provided by a Korean public broadcasting company in South Korea. {3-channel video dataset, 5-channel video dataset}
- Evaluation
 - Compare the ground-truth labeled data with output generated by our system at the frame level.
 - For the Quantitative Analysis, Analyze the frame-level alignment accuracy under various smoothing and temporal conditions.

	The 15	The 30	The 45
Best Path self-transition bias 0.71			
3-channel video	0.8499	0.8495	0.8495
5-channel video	0.8995	0.8999	0.8854
Best Path self-transition bias 0.91			
3-channel video	0.8499	0.8497	0.8481
5-channel video	0.8997	0.8910	0.8865

TABLE I: Match rates (Top Beam Paths) applying self-transition bias (0.70-0.9) varying the smooth threshold.

Length (s)	3-channel video		5-channel video	
	Match	Rate	Match	Rate
0-10	4,849	4.049	1,779	2.861
10-20	4,482	4.095	1,845	2.487
20-30	5,121	5.240	1,855	3.271
30-40	2,971	3.214	1,855	3.271
40-50	1,486	1.140	1,000	2.521
50-60	3,104	3.315	1,000	1.000
60-70	2,128	2.128	1,000	2.128
70-80	2,128	2.128	1,000	2.128
80-90	2,128	2.128	1,000	2.128
90-100	2,128	2.128	1,000	2.128
Total	22,871	26.400	8,499	10.100

TABLE II: Match rates across different segment lengths.

- For the Qualitative Analysis, Analyze subjective assessments of editing quality and viewer experience.
- The analysis was performed with 24 participants, including developers and broadcasting industry professionals, under a blind setup, where they were not informed whether a video was edited by our system or by a human expert.

	3-channel	5-channel
Criteria	One	Two
1. Speaker Switching Smoothness & Consistency	4.261031	4.516178
2. Is the current transition smooth when the speaker changes in the video?	4.261031	4.516178
3. Are the cut transitions in the video well-timed?	4.261031	4.516178
4. Does the video look like it was professionally edited?	4.261031	4.516178
5. All Editing Perceived	4.261031	4.516178
6. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
7. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
8. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
9. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
10. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
11. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
12. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
13. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
14. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
15. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
16. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
17. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
18. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
19. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
20. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
21. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
22. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
23. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178
24. If the AI-edited video was not professionally edited, what was the reason?	4.261031	4.516178

TABLE III: Subjective Video Quality Evaluation Results.




Fig. 2: Visualization of channel selection for the 3-channel (left column) and 5-channel (right column) videos. Each sub-figure shows the overall transitions and a detailed view with ground-truth labels.

02

Scientific Data (Nature Portfolio, SCIE, 2024 / 공동 저자)

A Military Audio Dataset for Situational Awareness and Surveillance

전쟁 및 경비 보안 환경의 특수성을 고려하여 총성, 포격, 교신 등 7대 핵심 군사 위험 소리를 수집하고 AST(Audio Spectrogram Transformer) 모델을 벤치마크 튜닝하여 91.07% 정확도를 확보한 공개 데이터셋.

♦ 국방 및 경계 감시 목적으로 8,075개의 위급 오디오 샘플(MAD)을 수집하여 오픈소스화하고, 로그 멜 필터뱅크 전처리 파이프라인 설계 및 오디오 스펙트로그램 트랜스포머 분류기의 특화 튜닝 벤치마크 실험을 총괄 수행하였습니다.

사용 기술: Audio Spectrogram Transformer (AST), Mel Filterbank, Python, Librosa

A Military Audio Dataset for Situational Awareness and Surveillance

Introduction

- Audio classification related to military activities is a challenging task due to the high levels of background noise and the lack of suitable and publicly available datasets.
- To bridge this gap, this paper constructs and introduces a new military audio dataset, named MAD, which is suitable for training and evaluating audio classification systems.
- The proposed MAD dataset is extracted from various military videos and contains 8,075 sound samples from 7 classes corresponding to approximately 12 hours, exhibiting distinctive characteristics not presented in academic datasets typically used for machine learning research.
- We further conduct a comprehensive sound classification study of various deep learning algorithms on the MAD dataset.

Method

- Methodology used to collect the MAD dataset



Fig. 1 Illustration of MAD dataset collection procedure.

- Data selection
 - Identify the audio content types for the seven military-related categories.
- Audio event segmentation
 - Identify the start and end times of each audio event.
- Data refinement
 - Refine the data using a variety of techniques, such as formatting, resampling, and extracting.
- Data labeling
 - Label all audio events into one of the seven predefined classes.
- Data configuration
 - Randomly split all the data into train/test sets with an approximately 9:1 ratio.

Dataset Overview

- Total Data: 8,075 audio events (12.05 hours in total)
- Dataset Split
 - Training Set: 7,393 samples (10.98 hours)
 - Test Set: 682 samples (1.07 hours)




Fig. 2 Bar chart illustrating the distribution of training and test sets according to various times.

Key Features

- All audio events range from 1 to 10 seconds in duration. Meticulously labeled and categorized for high-quality deep learning-based audio classification tasks.
- Total Classes: 7 audio classes, including Communication, Gunshot, Footsteps, Shelling, Vehicle, Helicopter, and Fighter.




Fig. 4 The overall pre-processing task for converting waveforms to Mel filterbank.

Technical Validation

- Model Evaluation: We conducted a comprehensive analysis of various deep learning models to evaluate the performance of the MAD dataset.
 - Models: ResNet, EfficientNet, CNN-N (PANNs), and AST (Audio Spectrogram Transformer).
- Pre-processing
 - Audio waveforms were converted into Log Mel filterbank features (80 dimensions, 25ms window, 10ms overlap).
 - All audio samples were standardized to a 10-second length using zero padding.
 - Standard normalization was applied to the spectrograms.
 - Augmentation: SpecAugment was used to mitigate overfitting.





Fig. 5 Illustration of overall deep learning-based audio classification process.

Experimental Result Summary

- Pretrained models consistently outperformed those trained from scratch. With pretrained weights, the AST-Patch-Mix model achieved the highest accuracy (91.07%), aligning with the trend that models with more parameters perform better. A notable exception was the CNN10 model, which achieved a strong 89.53% accuracy with only 6% of the parameters of the AST model.
- In contrast, when trained from scratch, the CNN14 model performed best (89.47%), while the high-parameter AST models surprisingly showed the lowest performance.



03


NeurIPS 2023 DGM4H Workshop (국제 학술대회 발표, 2023 / 공동 저자)

Adversarial Fine-tuning using Generated Respiratory Sound to Address Class Imbalance

의료 인공지능 진단의 클래스 불균형을 해결하기 위해 DiffWave 생성 모델을 설계하고, 원본과 생성 데이터 간의 분포 차이를 보완하는 적대적 미세조정(AFT) 기법을 제안하여 소수 질환 분류 정확도를 최대 26.58% 향상한 연구.

✦ 호흡 질환 진단 학습 셋의 희소 불균형을 해결하고자 오디오 디퓨전 생성기(DiffWave)를 구성하고, 라벨 분류기와 도메인 판별기를 융합한 적대적 튜닝(Label & Domain Adversarial) 미세 정밀 조정을 제안하여 의학 진단 모델의 희귀 질병 탐지 성능을 개선시켰습니다.

사용 기술: DiffWave, Domain Adversarial Training (DAT), Audio Synthesis, PyTorch



04

한국컴퓨터종합학술대회 (KCC 2023, 경진대회 장려상 / 공동 저자)

CutMix-SupCon: Supervised Contrastive Learning with CutMix Augmentation for Multimodal-based Emotion Recognition

한국어 음성(wav2vec 2.0) 및 텍스트(KLUE-RoBERTa) 인코더 임베딩 특징을 특징 공간상에서 결합(Latent CutMix)하고 지도 대조 학습(SupCon)을 통해 정렬하여 멀티모달 감정 분류 성능을 향상한 연구.

- 시청각/언어 데이터 병합 모델 구축의 일환으로 특징 공간 상에서의 보간 CutMix 기법과 코사인 유사도 정렬용 지도 대조 학습(SupCon) 구조를 구현하여 대조 특징을 정렬, 소수 감정 클래스 성능 보강(ETRI 주관 논문경진대회 장려상)에 기여했습니다.

사용 기술: wav2vec 2.0, KLUE-RoBERTa, Supervised Contrastive (SupCon), CutMix

CutMix-SupCon: Supervised Contrastive Learning with CutMix Augmentation for Multimodal-based Emotion Recognition

서론


- 멀티모달 데이터는 구조적으로 획득하기 어려운 문제가 있으며, 부족한 데이터 샘플의 문제로 인해 학습된 딥러닝 기반 네트워크의 실용화가 진행되기에는 여전히 한계점이 존재한다.
- 선행 연구들은 실제 환경의 부족한 데이터 문제는 고려하지 않고, 멀티모달 결합 관점에 대해서만 집중되는 경향이 존재한다.
- 본 연구에서는 멀티모달 데이터셋의 불충분한 문제를 해결하기 위해 CutMix-SupCon 방법을 제안한다. 제안된 CutMix-SupCon 방법은 잠재 공간에서 추출된 음성-텍스트 모델 간의 결합된 특징표현으로부터 혼합된 특징표현을 만들고, 혼합 대조 손실을 통해 음성-텍스트의 결합된 멀티모달 특징 표현이 원본과 얼마나 유사한지에 대한 목적 함수를 통해 최적화하였다.

방법

제안하는 멀티모달 CutMix-SupCon 방법은

- 멀티모달 특징표현 결합
- CutMix 기반 멀티모달 혼합 증강
- SupCon

으로 나뉘어지며, 전체 흐름도는 다음과 같다.



- CutMix 기반 멀티모달 혼합 증강
멀티모달 특징표현 $\mathbf{z}$ 과 레이블 y 에 대하여 샘플 $(\mathbf{x}_A, y_A)$, $(\mathbf{x}_B, y_B)$ 를 구성할 수 있고, 이로부터 새로운 샘플 $(\mathbf{z}, y)$ 를 아래의 식과 같이 만들 수 있다.

$$\mathbf{z} = M \odot \mathbf{x}_A + (1 - M) \odot \mathbf{x}_B$$

$$y = \lambda y_A + (1 - \lambda) y_B$$

- CutMix-SupCon
CutMix 기법으로부터 증강된 멀티모달 특징표현을 위한 적절한 손실 함수를 적용하기 위해, 잠재 공간내에서 혼합된 정보를 구분하여 효과적인 학습을 가능하게 하는 CutMix-SupCon 방법을 제안한다.

$$L_{CL} = \sum_{i \in I} \frac{1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(\mathbf{z}_i \cdot \frac{\mathbf{z}_p}{\gamma})}{\sum_{a \in A(i)} \exp(\mathbf{z}_i \cdot \frac{\mathbf{z}_a}{\gamma})}$$

$$L = L_{CE} + \alpha L_{CL}$$

위와 같은 최종 손실 함수를 통해 모델은 혼합된 멀티모달 특징표현이 원본의 샘플의 고유 정보를 얼마나 포함하는지를 학습한다.

실험 및 결과

- 데이터셋: KEMDy19 Text+Audio 멀티모달 감정인식 데이터셋
중복된 파일, 음성파 발화 세그먼트, 20초 이상의 음성 파일 제거 등의 전처리를 통해 10,214개의 데이터 샘플을 확보
학습 및 평가셋 8:2 무작위 분할
- 방법: 각 모달에 대한 특징표현 기반의 CE, Mixup, CutMix, 제안하는 Cutmix-SupCon 방법에 대한 결과 보고

Input	Method	Acc (%)	F1-score (%)
Text	Cross-Entropy	73.42	69.32
		72.59	67.13
Audio	Mixup	73.57	69.08
		71.76	67.37
Text+Audio	CutMix	71.46	65.89
		72.39	68.94
Text	CutMix-SupCon (ours)	72.93	69.37
		74.74	70.77
Audio	CutMix-SupCon (ours)	72.49	69.72
		72.54	68.27
Text+Audio	CutMix-SupCon (ours)	75.28	71.17

표 1 KEMDy19 데이터셋을 사용한 감정인식 평가 결과

Input	Method	Weighted F1-score(%)
Text+Audio	Cross-Entropy	73.55
	Mixup	72.39
	CutMix	74.77
	CutMix-SupCon (ours)	74.96




그림 2 KEMDy19 테스트 데이터 샘플에 대한 CE와 CutMix-SupCon의 예측 확률 분포 비교